

- 3.1 On considère trois modèles de régression emboîtés afin de modéliser le nombre d'accidents de voiture selon la région (*region*). La variable catégorielle niveaux de risque (*risque*) a 3 niveaux et le nombre d'années d'expérience (*expe*) au volant est un facteur à 4 niveaux.

| Modèle         | variables              | $p+1$ | $\ell(\hat{\beta})$ | AIC     | BIC     |
|----------------|------------------------|-------|---------------------|---------|---------|
| M <sub>1</sub> | risque                 | 3     | -244.566            | 495.132 | 510.362 |
| M <sub>2</sub> | risque + region        | ★     | -151.620            | ★       | ★       |
| M <sub>3</sub> | risque + region + expe | 10    | -139.734            | 299.468 | 350.235 |

Table 1: Mesures d'adéquation de trois modèles emboîtés avec les covariables, le nombre de coefficients du modèle ( $p+1$ ), la valeur de la log-vraisemblance évaluée au maximum de vraisemblance ( $\ell(\hat{\beta})$ ) et les critères d'information.

Quelle est la différence entre le AIC et le BIC du modèle M<sub>2</sub> (en valeur absolue)?

- 3.2 Une variable aléatoire  $X$  suit une loi géométrique de paramètre  $p$  si sa fonction de masse est

$$P(X = x) = (1 - p)^{x-1} p, \quad x = 1, 2, \dots$$

- Écrivez la vraisemblance et la log-vraisemblance d'un échantillon aléatoire de taille  $n$  si les observations sont indépendantes.
  - Dérivez l'estimateur du maximum de vraisemblance pour le paramètre  $p$ .
  - Calculez l'information observée.
  - Supposons qu'on a un échantillon de 15 observations,  $\{5, 6, 3, 7, 1, 2, 11, 8, 7, 34, 1, 7, 10, 1, 0\}$ , dont la somme est 103. Calculez l'estimé du maximum de vraisemblance et son erreur-type approximative.
  - Calculez la statistique du rapport de vraisemblance et la statistique de Wald pour un test à niveau 5% de l'hypothèse  $\mathcal{H}_0: p_0 = 0.1$  contre l'alternative bilatérale  $\mathcal{H}_a: p_0 \neq 0.1$ .
- 3.3 On considère le temps avant défaillance de machines sur la base de leur niveau de corrosion  $w$ . Spécifiquement, le temps avant défaillance,  $T$ , est modélisé à l'aide d'une loi exponentielle de densité  $f(t) = \lambda \exp(-\lambda t)$ , mais d'intensité  $\lambda = aw^b$ ; si  $b = 0$ , le temps de défaillance moyen est constant et vaut  $E(T_i) = a^{-1}$ . On suppose que les  $n$  observations sont indépendantes et que les niveaux de corrosion  $w_i$  sont supposés connus (donc fixes). [Coles (2001)]
- Écrivez la log-vraisemblance du modèle
  - Dérivez les matrices d'informations observées et de Fisher.
  - Montrez que la log-vraisemblance profilée pour  $b$  est

$$\ell_p(b) = n \ln(\hat{a}_b) + b \sum_{i=1}^n \ln(w_i) - \hat{a}_b \sum_{i=1}^n w_i^b t_i,$$

et dérivez une formule explicite pour l'estimateur du maximum de vraisemblance partiel  $\hat{a}_b$ .