

4.1 **Régression logistique** : on modélise le salaire de professeurs d'une université américaine pour une période de neuf mois. Le jeu de données `salairerprof` contient les variables suivantes :

- `sexe` : sexe, soit homme (0) ou femme (1);
- `echelon` : variable catégorielle, soit adjoint(e) (1), soit agrégé(e) (2), soit titulaire (3);
- `diplome` : diplôme le plus élevé complété, soit maîtrise (0) ou doctorat (1);
- `anec` : nombre d'années au sein de l'échelon académique;
- `andi` : nombre d'années depuis l'obtention dernier diplôme;
- `salaire` : salaire sur neuf mois (en dollars américains).

(a) Ajustez un modèle logistique pour modéliser la probabilité qu'un professeur ait un salaire supérieur à 105 000 USD en fonction de `diplome`, `sexe`, `anec` et `andi`. Écrivez l'équation du modèle ajusté et interprétez les paramètres du modèle.

Solution

L'équation du modèle ajusté est

$$\frac{\pi_i}{1 - \pi_i} = \exp(\beta_0 + \beta_1 \text{diplome}_i + \beta_2 \text{sexe}_i + \beta_3 \text{anec}_i + \beta_4 \text{andi}_i)$$

- $\exp(\beta_0)$ est la probabilité qu'un nouveau professeur adjoint qui termine sa maîtrise gagne plus de 105 000 dollars américains. L'estimation de cette probabilité est de 0,000286.
- $\hat{\beta}_1 = 18,58$; la cote d'un professeur avec un doctorat est 18,58 fois plus élevée que pour un professeur avec une maîtrise, toute chose étant égale par ailleurs.
- $\hat{\beta}_2 = 0,30$; la cote des femmes est 0,3 fois celles des hommes (70% moindre), ceteris paribus.
- Les deux derniers coefficients ne peuvent être interprétés séparément, à moins que la personne ne change d'échelon académique (auquel cas `anec` passe de x à 1. En général, la cote d'un professeur qui demeure au même rang augmente de $\exp(\hat{\beta}_3 + \hat{\beta}_4) = \exp(1,276 + 1,171) = 11,55$ par année.

(b) Ajoutez la covariable `echelon` en plus des autres variables. Arrivez-vous à identifier un problème avec ce nouveau modèle? Si oui, expliquez les résultats.

Solution

L'information fournie par `echelon` et le nombre d'années depuis le diplôme et au sein de l'échelon est partiellement redondante et engendre de la collinéarité. L'ordonnée à l'origine estimée est $\hat{\beta}_0 = -25,3$ dans R / $-11,1$ dans SAS, le coefficient pour les professeurs agrégés $\hat{\beta}_{\text{aggrege}} = 0,46$ dans R / $-5,72$ dans SAS et celui pour les titulaires de $\hat{\beta}_{\text{titulaire}} = 26,1$ dans R / $11,92$ dans SAS; cela signifie que le modèle prédit que tout le monde qui est dans les deux premiers échelons (adjoints et agrégés) a (en pratique) une probabilité nulle d'avoir un salaire excédant 105 000 dollars américains. Ces résultats numériques et l'instabilité des estimés sont dus à la quasi-séparation de variables.

4.2 Un chercheur en pédagogie est intéressé par la relation entre le nombre de prix remportés par des élèves d'une école secondaire et leurs notes en mathématique. On considère également le type de programme que les élèves fréquentent. Les données `prix` contiennent les variables suivantes :

- `nprix` : variable réponse, décompte du nombre total de prix reçus au cours de l'année scolaire.
- `math` : note de l'étudiant à l'examen final de mathématiques
- `prog` : programme d'étude de l'étudiant(e), un choix parmi général (1), programme enrichi (2) ou professionnel (3).

Ajustez une régression de Poisson et une régression binomiale négative en fonction des covariables `math` et `prog`. Comparez les résultats des deux modèles, indiquez si l'un ou l'autre est adéquat.

Solution

Le test du rapport de vraisemblance pour $\mathcal{H}_0 : k = 0$ (paramètre de dispersion du modèle de régression binomiale

négative) permet de comparer le modèle de Poisson (sous \mathcal{H}_0) au modèle binomiale négative (sous \mathcal{H}_1). La valeur- p est 0,096; on ne rejette pas l'hypothèse nulle; l'estimé du coefficient de dispersion est $\hat{k} = 0,1635 = 1/6,114$. Le ratio de la déviance par rapport au degrés de liberté résiduels du modèle de Poisson est 0,97, ce qui suggère que le modèle est adéquat.

4.3 **Taux** : les données `enfantsfiji` contiennent des information sur le nombre d'enfants nés, tirées de l'Étude de fertilité des Fiji. Les variables suivantes ont été mesurées pour plusieurs groupes de femmes :

- `nfemmes` : nombre de femmes dans le groupe;
- `nenfants` : variable réponse, nombre d'enfants nés;
- `dur` : temps (en années) depuis le mariage, un parmi 0–4 (1), 5–9 (2), 10–14 (3), 15–19 (4), 20–24 (5) et plus de 25 ans (6).
- `res` : variable catégorielle pour résidence, une parmi Suva (1), région urbaine (2) ou région rurale (3).
- `educ` : variable ordinale indiquant le niveau d'éducation, un parmi aucun (1), début du primaire (2), fin du primaire (3), secondaire ou plus (4).
- `var` : variance estimée intra-groupe du nombre d'enfants nés

(a) Tracez un graphique du nombre d'enfants nés (`nenfants`) en fonction du nombre de femmes dans le groupe (`nfemmes`) et commentez.

Solution

Il semble y avoir une relation linéaire claire entre les deux variables à l'échelle logarithmique. La relation entre moyenne et variance est nonlinéaire; la variabilité augmente pour les plus grands dénombrements.

- Devrait-on inclure un terme de décalage? Justifiez votre réponse.
- Si on inclut pas de décalage, quelle fonction (si aucune) de `nfemmes` devrait être incluse comme prédicteur?
- Si on inclut un décalage, comment ce modèle se compare-t-il au modèle qui inclut $\log(\text{nfemmes})$ comme prédicteur?

Solution

Les dénombrements ne sont pas comparables, donc un décalage est utile d'office. Le terme à inclure dans la moyenne pour obtenir le taux de naissances est $\log(\text{nfemmes})$. Si on voulait considérer plutôt un terme supplémentaire dans la moyenne, c'est $\log(\text{nfemmes})$ qui semble le plus adéquat au vu du graphe. On peut vérifier si le décalage est adéquat en testant si le coefficient pourrait être égal à un; l'intervalle de confiance à 95% basé sur la vraisemblance profilée est $[0,97; 1,06]$, ce qui ne suggère rien contre l'inclusion du nombre de femmes comme terme de décalage.

(b) Ajustez un modèle de régression de Poisson avec un décalage en incluant les trois variables catégorielles `dur`, `res` et `educ` sans interactions. Lequel des trois prédicteurs est le plus significatif?

Solution

La durée du mariage est la variable la plus significative globalement; la statistique est plus grande, mais il faut ajuster pour le nombre de paramètres additionnels (cinq); la valeur- p est la plus petite.

(c) Interprétez les estimés des coefficients du modèle ajusté.

Solution

L'interprétation change selon la paramétrisation du modèle; la solution suivante utilise les plus faibles catégories comme niveaux de référence, soit 0 – 4 ans depuis le mariage, habitantes de l'île de Suva, sans éducation).

- Le nombre moyen d'enfant nés par femmes pour les catégories de référence est $\exp(\hat{\beta}_0) = 0,89$
- Le nombre d'enfants par femme augmente par un facteur 2,7 pour 5–9 ans de mariage(respectivement 3,93 pour 10–14 ans; 5,02 pour 15–19 ans; 5,96 pour 20–24 ans et finalement 7,2 pour 25 ans et plus) par rapport à 0–4 ans de mariage,, *ceteris paribus*.

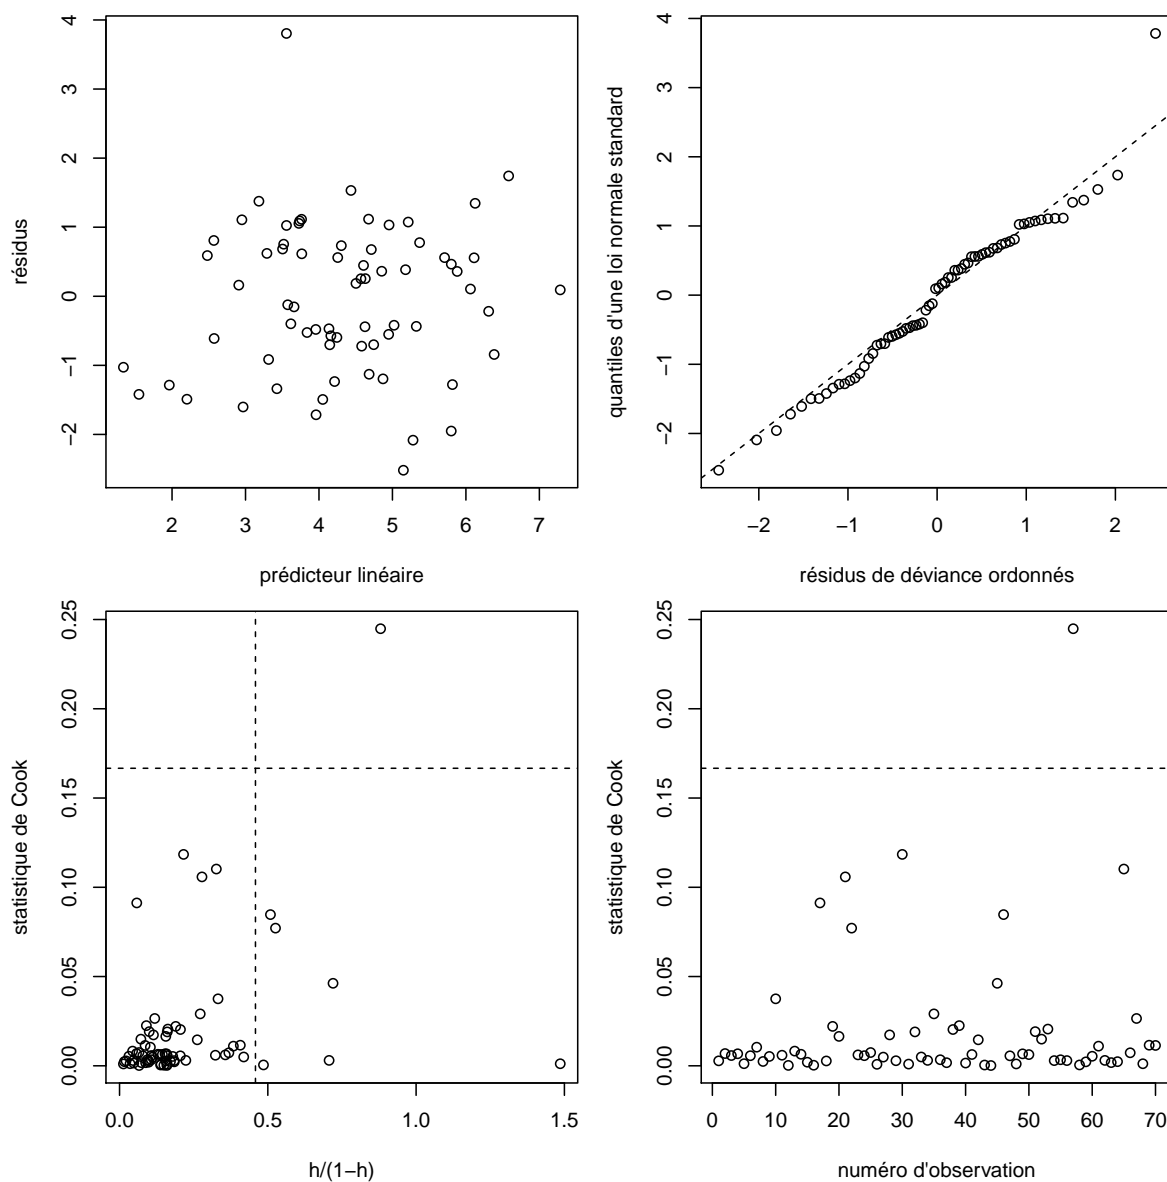


FIGURE 1 – Nombre d'enfants nés en fonction du nombre de femmes par groupe sur l'échelle log-log (gauche) et moyenne versus variance du nombre d'enfants nés par groupe (droite).

- L'augmentation relative du taux de natalité pour les femmes ayant complété au plus début-primaire est de 1,02 (respectivement 0,9 pour éducation fin-primaire et 0,73 pour une éducation secondaire ou supérieure), par rapport à aucune éducation. Règle générale, plus les femmes ont étudié, moins elles ont d'enfants.
 - Les personnes des zones urbaines aux îles Fiji ont 1,12 fois plus d'enfants qu'à Suva, tandis que ceux des zones rurales ont 1,16 fois plus qu'à Suva, pour un même niveau d'éducation et la même tranche d'années depuis le mariage.
- (d) Déterminez si une interaction entre `educ` et `duration` est utile en faisant un test du rapport de vraisemblance.

Solution

L'ajout de l'interaction donne 15 paramètres additionnels. On peut regarder le tableau de type 3 ou comparer la déviance du modèle avec et sans l'interaction. La statistique du rapport de vraisemblance est 15,86; a valeur- p de l'hypothèse nulle qu'ils sont tous simultanément zéro est 0,3912. On conclut qu'il n'y a pas de preuves que l'ajustement du modèle avec l'interaction est significativement meilleure.

- (e) Il est possible de vérifier l'adéquation du modèle à l'aide de diagnostics graphiques, notamment en étudiant les résidus de déviance du modèle de Poisson.¹ Produisez des diagnostics graphiques de (a) prédicteur linéaire versus résidus de déviance (b) diagramme quantile-quantile des résidus de déviance, (c) effet levier et (d) distance Cook en fonction des observations. Commentez sur l'ajustement du modèle de Poisson qui inclut trois variables explicatives catégorielles et le décalage. *Indication : l'interprétation est semblable à celle des modèles linéaires. Avec SAS, utilisez les options*

```
plots=(resdev(xbeta) leverage cooks)
```

Le diagramme quantile-quantile peut être produit avec la procédure univariate.

Dans R, la fonction `boot::glm.diag.plots` permet de produire les diagnostics graphiques.

Solution

Les diagnostics de la Figure 2 semblent bons; un seul résidu a un effet de levier, mais l'adéquation du modèle est excellente règle générale.

4.4 Données de location bixiuni : BIXI est une entreprise de location de vélos basée à Montréal. Nous avons extrait les données de location de BIXI pour la période 2017-2019 à la station Édouard-Montpetit en face de HEC. Notre intérêt est d'expliquer la variabilité observée dans le nombre de locations quotidiennes de vélos (mesuré par le nombre d'utilisateurs quotidiens) à cette station en fonction du jour de la semaine et d'indicateurs météorologiques. Les variables contenues dans la base de données sont les suivantes :

- `nutilisateurs` : nombre d'utilisateurs quotidiens à la station Édouard-Montpetit.
- `temp` : température (en degrés Celsius)
- `humid` : pourcentage d'humidité relative, prenant des valeurs comprises entre 0 et 100.
- `jour` : variable catégorielle indiquant le jour de la semaine et prenant des valeurs entre dimanche (1) et samedi (7).
- `fds` : variable binaire valant zéro si la location est effectuée pendant une fin de semaine (samedi ou dimanche) et un sinon.

On considère les quatre modèles suivants pour expliquer `nutilisateurs` :

- modèle 4.4.1 : modèle de régression de Poisson avec la covariable `fds`.
- modèle 4.4.2 : modèle de régression de Poisson, en incluant les covariables `fds`, `humid` et `temp`.
- modèle 4.4.3 : modèle de régression binomiale négative incluant les covariables `fds`, `humid` et `temp`.

1. Règle général, ces diagnostics sont plus difficiles à interpréter que ceux des modèles de régression linéaire parce que les observations sont discrètes tandis que les moyennes ajustées sont continues.

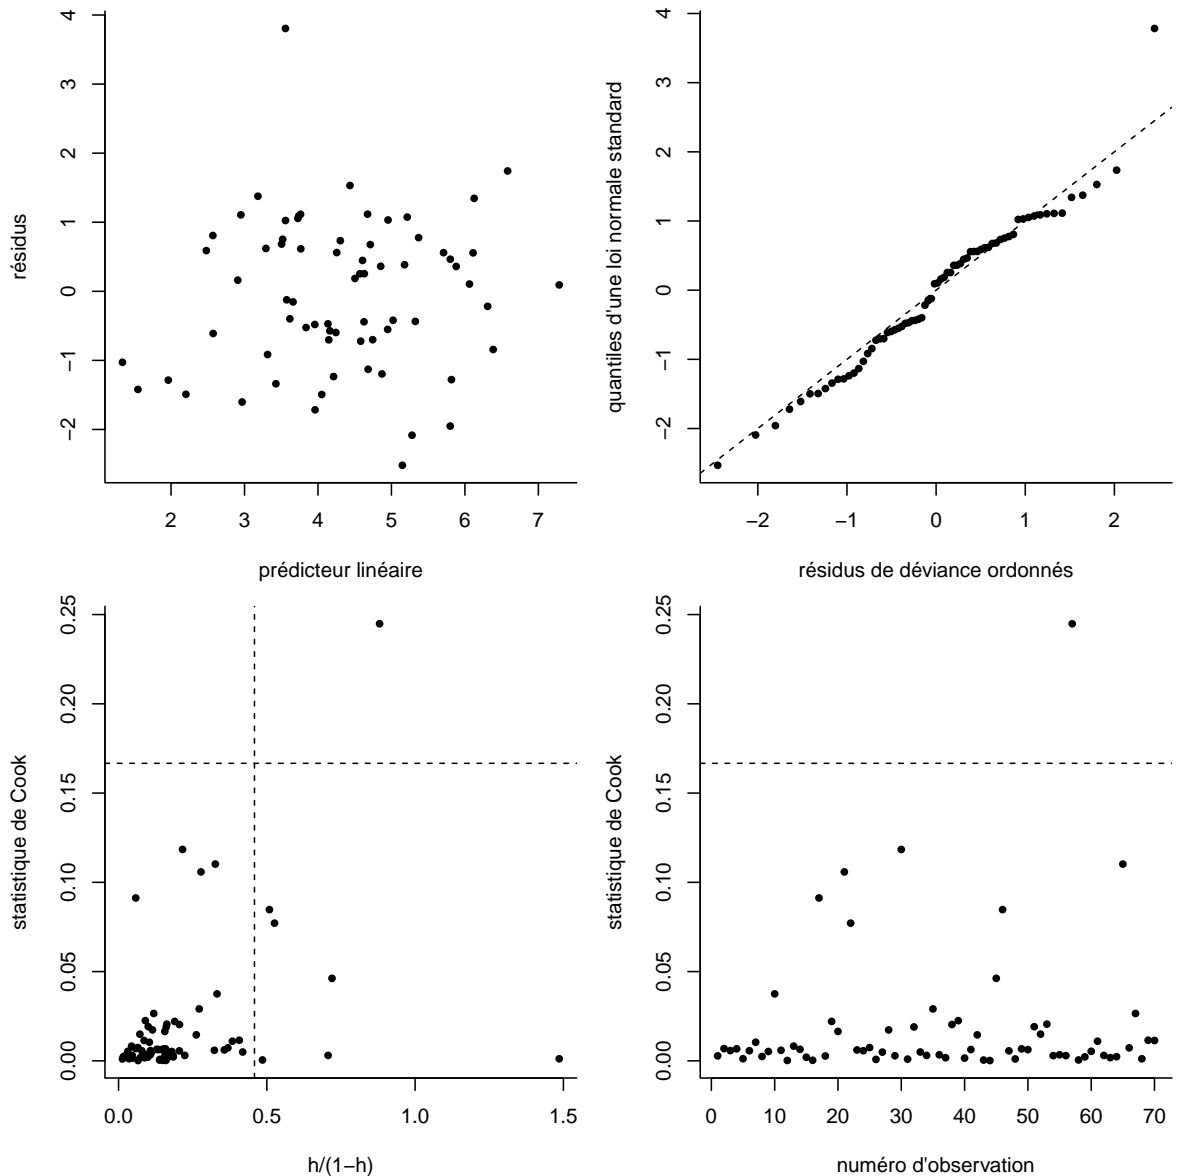


FIGURE 2 – Diagnostics graphiques pour les données `enfants` : des valeurs ajustées (prédicteur linéaire) contre les résidus de déviance (coin supérieur gauche), diagramme quantile-quantile des résidus de déviance (coin supérieur droit), distance de Cook versus effet de levier (coin inférieur gauche) et distance de Cook en fonction des indices des observations (coin inférieur droit)

- modèle 4.4.4 : modèle de régression binomiale négative incluant les variables explicatives `jour` (catégorielle), `humid` et `temp`.
- (a) Est-ce que le modèle 4.4.1 représente une simplification adéquate du modèle 4.4.2? Justifiez votre réponse en faisant un test d'hypothèse adéquat.

Solution

Les modèles sont emboîtés, donc on peut utiliser un test du rapport de vraisemblance pour les comparer. L'hypothèse nulle est $\mathcal{H}_0 : \beta_{\text{temp}} = \beta_{\text{humid}} = 0$. La statistique du test du rapport de vraisemblance est $2 \times (2577,3604 - 2190,8777) = 772,97$, à comparer à une loi χ^2_2 . On conclut qu'au moins un des effets linéaires

des variables explicatives `humid` et `temp` est statistiquement significatif.

- (b) Interprétez le coefficient estimé de l'ordonnée à l'origine et celui de la variable `humid` dans le modèle 4.4.2.

Solution

- Quand l'humidité relative est nulle et que la température est de 0°C , le nombre moyen d'utilisateurs quotidiens la semaine est $\exp(\hat{\beta}_0) = 13,07$.
- Pour chaque augmentation de l'humidité relative de 1%, *ceteris paribus*, le nombre moyen d'utilisateurs est multiplié par un facteur $\exp(\hat{\beta}_{\text{humid}}) = \exp(-0,0066) = 0,9934217$, soit une diminution de 0,657%.

- (c) Quel modèle choisiriez-vous parmi les deux modèles 4.4.2 et 4.4.3? Justifiez adéquatement votre réponse en utilisant tous les critères suivants : (a) la déviance (b) le test du rapport de vraisemblance et (c) les critères d'information.

Solution

- statistique de déviance : le rapport de la déviance sur les degrés de liberté est $1954/496 = 3,94$ pour la régression de Poisson tandis que ce même rapport pour le modèle de régression binomiale négative est $522,3013/496 = 1,0530$. Les deux modèles sont comparés aux modèles saturés à l'aide de rapports de vraisemblance; le modèle binomiale négative est adéquat (le rapport devrait être approximativement un).
- Le test du rapport de vraisemblance (problème irrégulier) entre le modèle 4.4.2 et le modèle 4.4.3 n'est pas donné dans la sortie. La log-vraisemblance complète est $-1808,0756$ pour la régression binomiale négative et $-2190,8777$ pour la régression de Poisson. La statistique du rapport de vraisemblance est égale à deux fois la différence de ces deux quantités, soit, 765,6042. Si on compare la statistique à $\frac{1}{2}\chi_1^2$, il apparaît que le modèle de Poisson n'est pas une simplification adéquate à cause de la surdispersion.
- Critères d'information : la valeur du AIC (respectivement du BIC) pour la régression de Poisson est 4389,75 (4406,6137), contre 3626,27 (3647,22) pour la régression binomiale négative; cela suggère que ce dernier modèle est préférable.

- (d) On suppose qu'on aimerait utiliser la variable `jour` à la place de la variable `fds`, comme variable explicative dans le modèle 4.4.4. Quelle serait la différence principale si on traitait la variable explicative `jour` comme entière plutôt que catégorielle? Indiquez laquelle de ces deux possibilités est plus logique dans ce contexte.

Solution

Seule la variable catégorielle est logique dans le contexte. Si on laisse les valeurs entières, cela implique un effet linéaire mais le fait qu'on assigne 1 à dimanche est arbitraire et les jours change de façon cyclique, ce qui ne peut être capturé avec une traîne linéaire.

- (e) L'espérance du nombre d'utilisateur selon le modèle 4.4.4 est

$$E(\text{nutilisateurs}) = \exp(\beta_0 + \beta_1 \text{temp} + \beta_2 \text{humid} + \beta_3 \mathbf{1}_{\text{jour}=2} + \beta_4 \mathbf{1}_{\text{jour}=3} + \beta_5 \mathbf{1}_{\text{jour}=4} + \beta_6 \mathbf{1}_{\text{jour}=5} + \beta_7 \mathbf{1}_{\text{jour}=6} + \beta_8 \mathbf{1}_{\text{jour}=7}).$$

Écrivez l'hypothèse nulle du test comparant le modèle 4.4.3 au modèle 4.4.4 en fonction des paramètres β du modèle, ce faisant démontrant que les deux modèles sont emboîtés. Est-ce que le nombre d'utilisateurs change selon le jour de la semaine ou de fin de semaine?

Solution

Un énième test de rapport de vraisemblance pour comparer le modèle 4.4.3 et le modèle 4.4.4. L'hypothèse nulle (en fonction des paramètres du modèle) est $\mathcal{H}_0 : \beta_3 = \beta_4 = \beta_5 = \beta_6 = \beta_7, \beta_8 = 0$, et donc les modèles sont bel et bien emboîtés. La statistique vaut $2 \times (1808,0756 - 1801,7758) = 12,6$, à comparer à une variable de loi χ_5^2 . La valeur- p est 0,027, on rejette donc \mathcal{H}_0 à niveau 5% pour conclure que le nombre moyen (sachant les facteurs météorologiques) varient selon les jours de semaine et de fin de semaine.

4.5 **Parties de soccer** : Soit Y_{ij} (resp. Z_{ij}) le score de l'équipe à domicile (resp. visiteurs) pour une partie de soccer opposant les équipes i et j . Maher (1982) a suggéré de modéliser les scores via

$$Y_{ij1} \sim \text{Po}\{\exp(\delta + \alpha_i + \beta_j)\}, \quad Y_{ij2} \sim \text{Po}\{\exp(\alpha_j + \beta_i)\}, \quad i \neq j; i, j \in \{1, \dots, 20\}, \quad (\text{E4.5.1})$$

où α_i représente la puissance offensive de l'équipe i , β_j la puissance défensive de l'équipe j et δ l'avantage du terrain commun à toutes les équipes qui jouent à domicile. Les points des deux équipes et de parties différentes sont supposés indépendants les uns des autres. La base de donnée soccer contient les résultats des parties de soccer pour la saison 2015 de la *English Premier Ligue* (EPL), avec les variables suivantes :

- buts : nombre de buts comptés durant la partie par equipe.
- equipe : variable catégorielle indiquant le nom de l'équipe qui a compté les buts.
- adversaire : variable catégorielle donnant le nom de l'adversaire.
- domicile : variable binaire, 1 si equipe joue à domicile, 0 sinon.

Note : les buts d'une même partie ne sont pas adjacents parce que la base de données est triée par domicile. Par exemple, la première partie oppose Manchester U. (1 but, ligne 1) à domicile à Tottenham (0 but, ligne 381).

- (a) Un avantage du terrain δ commun à toutes les équipes est logique pourvu que le nombre de buts comptés à domicile soient indépendants de ceux comptés à l'extérieur, c'est-à-dire en l'absence de terme d'interaction entre les pointages. Pour vérifier cette hypothèse, on agrège les pointages de chaque partie durant la saison et on construit un tableau de contingence à deux facteurs (Table 1) pour les points de l'équipe à domicile versus ceux de l'équipe adverse. Le fichier socceragg contient ce tableau de contingence en format long; à l'aide de ces données, testez l'hypothèse d'indépendance et concluez.

domicile	visiteur						
	0	1	2	3	4	5	6
0	32	33	9	14	3	0	1
1	37	41	28	11	3	1	0
2	27	25	29	7	2	1	0
3	18	15	10	5	2	0	0
4	9	6	3	0	0	1	0
5	0	4	0	0	0	0	0
6	0	1	2	0	0	0	0

TABLE 1 – Nombre d'occurrences de scores pour les parties de soccer de l'EPL

Solution

Tester « l'indépendance » revient à tester si le terme d'interaction entre visiteur et domicile dans le modèle saturé est statistiquement différent de zéro. La statistique de déviance pour le modèle de Poisson sans interaction vaut 43.8, à comparer à une loi χ^2_{36} sous l'hypothèse nulle d'indépendance. La valeur- p est 0.825; on ne rejette pas l'hypothèse nulle que le modèle plus simple (sans adéquat), ce qui suggère ici que l'avantage maison commun est adéquat.

- (b) Ajustez le modèle de l'Equation (E4.5.1) et répondez aux questions suivantes :
- i. À l'aide du modèle ajusté, donnez le nombre moyen de buts comptés par chaque équipe dans une partie opposant Manchester United (à domicile) et Liverpool.
 - ii. Rapportez et interprétez l'avantage du terrain estimé, $\hat{\delta}$.
 - iii. Testez si l'avantage du terrain δ est significativement différent de zéro.
 - iv. La loi asymptotique de la statistique de déviance D est χ^2_{n-p-1} . Cette approximation n'est valable que quand le nombre d'observations dans chaque groupe est grand, or seules 38 parties sont disputées par

niveau	2.5%	5%	10%	25%	50%	75%	90%	95%	97.5%
quantile	760.53	770.33	782.30	803.41	826.25	849.92	871.23	885.74	897.44

TABLE 2 – Quantiles des statistiques de déviance simulées selon le modèle de Maher (1982)




FIGURE 3 – Loi nulle asymptotique (courbe) et simulée (histogramme) pour la statistique de déviance du modèle E4.5.1.

chaque équipe à domicile et à l'extérieur. On peut approximer plutôt la loi nulle de D par simulation en répétant $B = 10\,000$ fois les étapes suivantes :

- générer de nouvelles données de loi Poisson du modèle ajusté,
- ajuster la régression de Poisson donnée par l'Equation (E4.5.1) aux données simulées,
- calculer la statistique de déviance.

Le Table 2 donne les quantiles empiriques des $B = 10\,000$ valeurs de déviance obtenues sur les données simulées. Commentez sur la qualité de l'ajustement sur la base de la statistique de déviance et du Table 2. Contrastez vos conclusions avec celles obtenues en utilisant l'approximation asymptotique χ^2 de la loi nulle de la déviance.

Solution

- On remplace les coefficients estimés dans l'eq. (E4.5.1) pour obtenir les prédictions, soit 1.385 buts pour Manchester United et 1.01 pour Liverpool.
 - L'avantage maison estimé est de $\hat{\delta} = 0.21$ avec intervalle de confiance basé sur le vraisemblance profilée à 95% de $[0.0088; 0.33]$. Cela correspond à une augmentation moyenne de 23.5% du nombre de buts comptés à domicile par n'importe quelle équipe durant un match.
 - La statistique du rapport de vraisemblance pour comparer le modèle ajusté avec le même modèle sans avantage domicile est 11.39. Par rapport à la loi asymptotique de référence, χ^2_1 , ce résultat est peu plausible et on rejette l'hypothèse nulle que $\delta = 0$ (valeur- p de 0.00074).
 - La déviance (829.78) semble grande par rapport aux degrés de liberté (720) ; le rapport entre les deux est 1.15, avec une valeur- p dérivée à partir de la loi asymptotique χ^2 de 0.0027 ; voir Figure 3. En revanche, cette approximation n'est pas fiable : sur la base des données simulées, la déviance est presque égale à la médiane des statistiques simulées, donc aucune preuve contre l'hypothèse nulle que le modèle ajusté est une simplification adéquate du modèle saturé.
- (c) Maher a aussi suggéré des modèles plus complexes, dont un dans lequel la force offensive et défensive différerait selon que l'équipe soit à domicile ou à l'extérieur, à savoir

$$Y_{ij1} \sim \text{Po}\{\exp(\alpha_i + \beta_j + \delta)\}, \quad Y_{ij2} \sim \text{Po}\{\exp(\gamma_j + \omega_i)\}, \quad i \neq j; i, j \in \{1, \dots, 20\} \quad (\text{E4.5.2})$$

Est-ce que le modèle (E4.5.2) est significativement meilleur que le modèle (E4.5.1) ?

Solution

Pour ajuster le Modèle (E4.5.2), on peut inclure les termes d'interaction $\text{equipe} \cdot \text{domicile}$ and $\text{adversaire} \cdot \text{domicile}$. Les deux modèles sont emboîtés puisqu'on recouvre le modèle (E4.5.1) en fixant tous les paramètres de ces interactions à zéro. Le premier modèle a 40 paramètres, le second a 79 paramètres et donc la statistique du rapport de vraisemblance, ici 47.86, suit approximativement une loi χ^2_{38} sous \mathcal{H}_0 . La valeur- p vaut 0.13, ce qui suggère que le modèle plus complexe ((E4.5.2)) n'est pas significativement meilleur que le modèle plus simple ((E4.5.1)).

- (d) Est-ce qu'un modèle de Poisson similaire serait adéquat pour le pointage d'une partie de basketball? Expliquez votre réponse. *Indice : quel est le nombre de points comptés en moyenne lors d'une partie?*

Solution

Sur la base des données des dix dernières années, le score moyen des matchs de la NBA est de 103 points par match avec un écart-type de 12.89 points. La variance serait donc supérieure à la moyenne, donc la loi de Poisson serait peut-être inadéquate à cause de la surdispersion.

- 4.6 **Bush vs Gore** : L'élection présidentielle américaine de 2000 opposait Georges W. Bush (Républicain) et Albert A. Gore (Démocrate), ainsi qu'une quantité de candidats marginaux. La Floride a été remportée par Bush par une mince marge de 537 votes, ce qui en a fait l'état pivot déterminant le vainqueur de l'élection. Plusieurs analystes ont affirmé que les bulletins de vote de type papillon utilisés dans les quartiers pauvres du comté de Palm Beach ont mené à la confusion d'électeurs et ont dépossédé Al Gore de quelques milliers de voix qui ont été à un tiers candidat d'extrême droite, Patrick Buchanan (Réforme). Smith (2002) a analysé les résultats de l'élection par comté et s'est intéressé au décompte du comté de Palm Beach, dans lequel un nombre anormalement élevé d'électeurs (3407) exprimaient une préférence pour Buchanan.

Le but de cet exercice est de construire un modèle pour prédire le nombre moyen de votes pour Buchanan dans le comté de Palm Beach sur la base de ses résultats dans les autres comtés. Les données buchanan contiennent les variables suivantes pour chacun des 67 comtés de l'État de Florida :

- `comte` : nom du comté
- `popn` : population du comté en 1997.
- `blanc` : pourcentage de « blancs » [*sic*] en 1996 (selon le questionnaire du recensement; personnes ayant des origines européennes, nord-africaines ou moyen-orientales (définition du recensement)).
- `noir` : pourcentage de « noirs » [*sic*] ou Afro-Américains (personnes ayant des origines d'Afrique sub-saharienne), en 1996.
- `hisp` : pourcentage d'hispaniques (groupe ethnique) en 1996.
- `a65` : pourcentage de la population âgée de plus de 65 ans selon les estimés de population de 1996 et 1997.
- `dsec` : pourcentage de la population avec un diplôme d'études secondaires (recensement de 1990).
- `coll` : pourcentage de la population diplômée d'un collège (recensement de 1990).
- `revenu` : revenu moyen individuel en 1994.
- `buch` : nombre de votes pour Pat Buchanan.
- `bush` : nombre de votes pour Georges W. Bush.
- `gore` : nombre de votes pour Al Gore.
- `totmb` : nombre total de bulletins de vote, moins les votes pour Buchanan.

- (a) Calculez la proportion totale de votes obtenus pour Buchanan pour toute la Floride.
 (b) Produisez un graphique du pourcentage de votes obtenus par Buchanan, $\text{buch}/(\text{buch}+\text{totmb})$, versus $\ln(\text{popn})$ et commentez.

Solution

Selon la Figure 4, la proportion des suffrages exprimés pour Buchanan est plus grande dans les petits comtés (ruraux). Il y a une valeur aberrante bien visible, approximativement située à $[13, 0.75\%]$. Cette observation




FIGURE 4 – Pourcentage des suffrages exprimés pour Buchanan en fonction du log de la population du comté (gauche) et nombre de votes en fonction du nombre de bulletins de vote exprimés. Le point en rouge, une valeur aberrante, correspond au comté de Palm Beach.

correspond au comté de Palm Beach. Il y a plus d'hétérogénéité observée dans les comtés moins densément peuplés.

Excluez les résultats de Palm Beach pour le reste de la question en remplaçant la valeur de buch par une valeur manquante.

- (c) On considère d'abord un modèle de Poisson pour le pourcentage de votes obtenus par Buchanan, buch/totmb , en fonction de blanc , $\ln(\text{hisp})$, a65 , dsec , $\ln(\text{coll})$, revenue .
 - i. Expliquez l'utilité d'utiliser un terme de décalage dans ce problème.
 - ii. Pourquoi est-ce que totmb est un meilleur choix de dénominateur que popn pour le taux d'appuis? Expliquez.
 - iii. Est-ce que le modèle de régression de Poisson est approprié? Justifiez votre réponse.
 - iv. Expliquez pourquoi, s'il y a des preuves de surdispersion, cela implique forcément qu'un modèle de régression binomiale est inadéquat. *Indice : quelle est la variance de la loi binomiale et comment cette dernière se compare à la loi Poisson pour un taux?*
- (d) Ajustez le même modèle, mais cette fois-ci avec une loi binomiale négative. Utilisez ce modèle pour prédire le nombre moyen de votes pour Buchanan dans le comté de Palm Beach. Commentez sur la différence entre le nombre de votes obtenus par Buchanan et cette prédiction.

Solution

- (a) La population dans les comtés diffère drastiquement, allant de 6.3K à 2 millions de votants.
- (b) On s'intéresse au pourcentage de votes, donc totmb — le pourcentage de votes pour Buchanan, est inférieur à 1.5%, donc l'omettre du dénominateur n'affectera pas les résultats et permettra de ne pas utiliser l'observation pour la prédiction (ce point est discutable). Utiliser popn pour construire un terme de décalage ne serait pas approprié parce que le taux de participations varie fortement selon le comté, allant de 25% à 58%. Cela peut être dû au fait que certains habitants n'ont pas la citoyenneté américaine ou ont un casier judiciaire, ou à des populations plus jeunes (seuls les adultes peuvent voter).
- (c) La somme combinée de ces deux score vaut presque 100%, ce qui créerait de la colinéarité.
- (d) Puisque le nombre d'essais est grand, on s'attend que l'approximation χ^2 pour la déviance tienne. La statistique de déviance pour l'échantillon, en excluant le comté 50, vaut $D = 596.25$ avec $\nu = 58$ degrés de liberté

résiduels, un rapport de presque 10! Il y a clairement de la surdispersion : un test pour un modèle avec la même structure de moyenne, mais avec une loi binomiale négative donne une statistique de rapport de vraisemblance de 379.582, une preuve accablante contre le postulat d'égalité moyenne-variance.

- (e) La variance d'une loi binomiale est $N_i p_i (1 - p_i)$, alors que celle de la loi de Poisson correspondant serait $N_i p_i$. Puisque $p_i \approx 0.003$, le terme $1 - p_i$ est négligeable et la surdispersion pour la fraction ne pourrait pas être prise en compte par un modèle de régression logistique avec données binomiale.
- (f) La prédiction est de 504 votants, comparativement à 438 pour la loi Poisson. Les logiciels ne retournent que l'incertitude de la moyenne, or il y a une part importante de la variabilité qui est due à la loi sous-jacente des observations. On peut prendre cette dernière en compte et obtenir un intervalle de prédiction approximatif à l'aide d'une étude Monte Carlo en simulant d'abord de nouveaux paramètres $\beta \sim \text{No}_{p+1}\{\hat{\beta}, j^{-1}(\hat{\beta})\}$, puis en échantillonnant un jeu de données correspondant d'une loi binomiale négative et en ré-estimant notre modèle pour obtenir une prédiction. En répétant ces étapes B fois, on obtient un intervalle de prédiction à partir des quantiles 0.025 et 0.975 de ces prédictions simulées, ici [261 ; 861] avec $B = 10\,000$ répliques.

4.7 Tableau de contingence à deux facteurs : les données de dénombrement sont souvent fournies sous forme de tableaux de contingence; on considère un tableau bidimensionnel avec J et K niveaux. Le même format peut être utilisé pour stocker le nombre de réussites et d'échecs dans chaque cellule. La moyenne du modèle **saturé** pour la cellule j, k (modèle avec deux effets principaux et une interaction) est

$$\text{logit}(p_{jk}) = \alpha + \beta_j + \gamma_k + \nu_{jk}, \quad j = 1, \dots, J-1; k = 1, \dots, K-1. \quad (M_s)$$

et a $JK = 1 + (J-1) + (K-1) + (J-1)(K-1)$ paramètres. On peut considérer des modèles plus simples :

- M_0 : le modèle nul $\text{logit}(p_{jk}) = \alpha$ a un paramètre
- M_1 : le modèle avec uniquement première variable catégorielle, $\text{logit}(p_{jk}) = \alpha + \beta_j (j = 1, \dots, J-1)$, a J paramètres
- M_2 : le modèle avec uniquement deuxième variable catégorielle, $\text{logit}(p_{jk}) = \alpha + \gamma_k (k = 1, \dots, K-1)$, a K paramètres
- M_3 : le modèle additif avec les deux effets principaux, $\text{logit}(p_{jk}) = \alpha + \beta_j + \gamma_k (j = 1, \dots, J-1; k = 1, \dots, K-1)$, a $J + K - 1$ paramètres.

La déviance mesure la **différence d'ajustement** entre le modèle saturé et un modèle emboîté plus simple. Sous des conditions de régularité et en assumant que le nombre d'observations dans chacune des JK cellules tend vers ∞ ,

$$D(\hat{\beta}_{M_i}) = 2\{\ell(\hat{\beta}_{M_s}) - \ell(\hat{\beta}_{M_i})\} \sim \chi^2_{JK-p_i}$$

sous l'hypothèse nulle que le modèle M_i avec p_i paramètres est une simplification adéquate du modèle saturé. Comme pour l'ANOVA, on procède par élimination en partant du modèle le plus compliqué et on compare la différence de déviance entre modèles emboîtés $M_i \subset M_j$; cette différence $D(\hat{\beta}_{M_i}) - D(\hat{\beta}_{M_j})$ suit approximativement une loi $\chi^2_{p_j-p_i}$ dans de grands échantillons si M_i est une simplification adéquate de M_j (la comparaison de déviance revient à calculer la statistique du rapport de vraisemblance).

Une fois qu'on a terminé la sélection, on obtient un modèle M_i , disons. Si le modèle M_i est adéquat et qu'on a plusieurs milliers d'essais, alors $D(\hat{\beta}_{M_i}) \sim \chi^2_{JK-p_i}$ et son espérance devrait être approximativement égale à $JK - p_i$. Modélisez les données cancer avec un modèle de régression logistique (loi binomiale et fonction liaison logit). La base de données contient deux variables explicatives catégorielles, age et maligne, qui ont trois et deux niveaux respectivement. Faites une analyse de déviance et sélectionnez le meilleur modèle par élimination en partant du modèle saturé (procédure descendante).

Solution

Il y a $JK = 6$ paramètres dans le modèle saturé.

On compare d'abord le modèle additif, M_3 , au modèle saturé avec $JK = 6$ coefficients. La déviance est de 0,49 et,

modèle	déviance	p	covariables
M_0	12,66	1	aucune
M_1	6,64	3	age
M_2	5,96	2	maligne
M_3	0,49	4	age, maligne

TABLE 3 – Analyse de déviance pour les données cancer

sous l'hypothèse nulle $\mathcal{H}_0 : v_{jk} = 0, j = 1, \dots, J-1, k = 1, \dots, K-1, D(\hat{\beta}_{M_3}) = 0,49 \sim \chi_2^2$ asymptotiquement. La valeur- p du test est de 0,78, donc on ne rejette pas l'hypothèse nulle que le modèle additif M_3 est une simplification adéquate du modèle saturé.

On peut ensuite comparer le modèle M_3 aux modèles M_2 et M_1 . Considérons d'abord M_3 versus M_2 , ce qui correspond à l'hypothèse nulle $\mathcal{H}_0 : \beta_j = 0 (j = 1, \dots, J-1)$; la statistique du test du rapport de vraisemblance $D(\hat{\beta}_{M_2}) - D(\hat{\beta}_{M_3}) \sim \chi_{p_3-p_2}^2$; on compare la valeur de la statistique, 5,46, aux quantiles de la loi χ_2^2 . Le 95% percentile de la loi χ_2^2 est 5,99, donc on ne rejette pas l'hypothèse nulle à niveau 5% que M_2 est une simplification adéquate de M_3 . La valeur- p est de 0,065.

On aurait aussi pu comparer le modèle M_3 au modèle M_1 ; la statistique du test de rapport de vraisemblance est $6.64 - 0.49 = 6.15$; cette valeur est à comparer au 95% de la loi χ_1^2 , soit 3,84. La valeur- p est 0,013, donc le coefficient associé à maligne est significativement différent de zéro.

Finalement, on peut comparer M_2 à M_0 . L'hypothèse nulle est $\mathcal{H}_0 : \gamma_k = 0 (k = 1, \dots, K-1)$ et la valeur- p est 0,009; les paramètre pour maligne est une fois de plus différent de zéro. (★) Si le modèle M_2 était adéquat, la déviance suivrait approximativement une loi χ_4^2 (mais la loi de référence ici dépend des vrais paramètres du modèle, lesquels sont inconnus). La déviance de M_2 est 5,96 et la valeur- p approximative est 0,25. Cette approximation pourrait être douteuse dans la mesure où le nombre pour chaque scénario du plan d'expérience est fortement déséquilibré (il y a moins de patients dans les tranches d'âge supérieures). Une meilleure façon de vérifier l'adéquation est de simuler des nouvelles données du modèle ajusté en conditionnant sur le nombre de patients par tranche d'âge et le status du cancer pour obtenir une loi empirique pour la déviance et la comparer à la loi χ_4^2 ; dans notre exemple, il semble que cette dernière soit adéquate (voir code R).

- 4.8 **Équivalence entre les modèles de régression Poisson et binomiale :** Si $Y_j \sim \text{Bin}(m_j, p_j)$ et $m_j p_j \rightarrow \mu_j$ quand $m_j \rightarrow \infty$, on peut approximer la loi de Y_j par une loi Poisson $\text{Po}(\mu_j)$. De ce fait, on pourrait considérer un modèle linéaire généralisé avec

$$\log(\mu_j) = \log(m_j) + \log(p_j).$$

Dans ce modèle, m_j est une constante fixe et le coefficient du prédicteur $\log(m_j)$ est exactement un; c'est un terme de décalage.

- Ajustez les modèles M_0, \dots, M_3 à l'aide d'une vraisemblance binomiale et une fonction de liaison logistique pour les données fumeurs. Ce jeu de données contient le nombre de cas de cancer du poumon par tranche d'âge (age) et par habitude (fume). Rapportez la valeur de la déviance et le nombre de degrés de liberté du modèle (nombre de paramètres). Faites une analyse de déviance séquentielle descendante. Répétez votre analyse avec une régression de Poisson possédant un terme de décalage.
- Comparez les résultats obtenus à l'aide du modèle de régression logistique et de régression de Poisson en terme de probabilité de décès pour chaque catégorie.

Solution

- On procède par élimination séquentielle descendante en partant du modèle saturé avec $m = 36$ paramètres, qu'on compare d'abord au modèle M_3 ; cette comparaison revient à tester $\mathcal{H}_0 : v_{jk} = 0, j = 1, \dots, J-1; k = 1, \dots, K-1$. La valeur- p est 0,61 pour le modèle de Poisson et 0,55 pour le modèle binomial. On n'a pas de

preuve que le modèle M_3 n'est pas une simplification adéquate du modèle saturé. Le modèle saturé ne peut pas être davantage simplifié et semble adéquat dans la mesure où $D(\hat{\beta}_{M_3}) \approx m - p = 24$.

modèle	déviante (binom.)	déviante (Poisson)	p
M_0	4055,98	4917,03	1
M_1	3910,70	4740,34	4
M_2	191,72	247,94	9
M_3	21,49	22,44	12

TABLE 4 – Analyse de déviante pour les données fumeurs

- (b) On voit que, pour certaines catégories pour lesquelles le taux de mortalité relié au cancer du poumon est élevé, l'approximation de Poisson à la loi binomiale n'est pas bonne et les différences sont plus marquées entre les deux modèles.

